



Universidad Internacional de la Rioja (UNIR)

ESIT

Máster Universitario en Inteligencia Artificial

Detección de caídas con Wearables y GRU

Trabajo Fin de Máster

presentado por: Aritz Beraza Garayalde

Dirigido por: ?????

Ciudad: Paris

Fecha: 13:04

Índice de Contenidos

1. Intro	3
1.1. Introducción	3
1.1.1. Motivación	3
1.1.2. planteamiento del trabajo	4
1.1.3. Estructura de la memoria	5
2. Contexto y Estado del Arte	6
2.1. Precedentes en detección de caídas	6
2.1.1. Primeros pasos, cálculos basados en cotas	6
2.1.2. IA para detección de caídas	7
2.2. GRU vs LSTM para predicción de series	8
2.3. Pruning y técnicas para reducir complejidad de modelos	9
3. Objetivos	10
3.1. Objetivo General	10
3.2. Objetivos Específicos	11
3.3. Metodología de trabajo	11
4. Identificación de requisitos	13
5. Descripción de la herramienta desarrollada	14
6. Evaluación	15
7. Conclusiones y Trabajo Futuro	16
7.1. Conclusiones	16
7.2. Lineas de trabajo futuro	16

A. Captura de datos y construcción del dataset	21
A.1. Captura de datos y creación del dataset	21
A.1.1. Necesidad	21
A.1.2. Captura de datos: AccelCapture	22
A.1.3. Dispositivo de captura	22
A.1.4. Preprocesado de los datos	22
B. Artículo	25

Índice de Ilustraciones

Índice de Tablas

A.1. Especificaciones del dispositivo de referencia	23
---	----

Resumen

En sociedades cada vez más envejecidas aumenta la necesidad de controlar de forma continua la salud de las personas mayores, y en concreto identificar las caídas, una de las principales causas de mortalidad en personas mayores. A este respecto existen hoy en día soluciones que sirven únicamente a este propósito, altamente intrusivas, o soluciones basadas en un reloj inteligente y una unidad de procesamiento independiente que reduce la autonomía. En este trabajo se presenta un sistema de detección de caídas que funciona de forma autónoma en un reloj inteligente o smartwatch ofreciendo un alto grado de precisión en un sistema no intrusivo y autónomo como es un reloj de pulsera.

Palabras Clave: Detección de caídas, RNN, LSTM, Detección Anomalías

Abstract

En sociedades cada vez más envejecidas aumenta la necesidad de controlar de forma continua la salud de las personas mayores, y en concreto identificar las caídas, una de las principales causas de mortalidad en personas mayores. A este respecto existen hoy en día soluciones que sirven únicamente a este propósito, altamente intrusivas, o soluciones basadas en un reloj inteligente y una unidad de procesamiento independiente que reduce la autonomía y portabilidad. En este trabajo se presenta un sistema de detección de caídas que funciona de forma autónoma en un reloj inteligente o smartwatch ofreciendo un alto grado de precisión en un sistema no intrusivo y autónomo como es un reloj de pulsera.

Palabras Clave: Detección de caídas, Detección de Actividad, RNN, LSTM, Detección Anomalías

The need to continuously monitor elder people's health, and specially detect falls, one of the main death causes of this population, increases in an aging society. To solve this many solutions exist nowadays, but they are either based in expensive proprietary one purpose hardware which is highly obtrusive or in the capture of data through a wearable and a linked device that processes it making it less portable and not quite autonomous. This work will present a fall detection system based purely in a smartwatch, offering high precision detection in an unobtrusive and autonomous wristwatch.

Keywords: Fall Detection, Human Activity Detection, RNN, LSTM, Outliers detection

Capítulo 1

Intro

1.1. Introducción

Resumen esquemático de cada una de las partes del trabajo. Leer esta sección ha de dar una idea clara de lo que se pretendía y las conclusiones a las que se han llegado y del proceso seguido Es uno de los capítulos mas importantes

1.1.1. Motivación

Problema a tratar posibles causas relevancia del problema

Este trabajo resulta de especial interés en el contexto actual en el que las sociedades de los países desarrollados sufren un rápido envejecimiento de sus poblaciones. El control continuo de diferentes parámetros de salud de poblaciones propensas a estos permite ofrecer atención de calidad a menor coste. En este contexto es especialmente importante la detección de caídas. Las caídas son la principal causa de mortalidad de personas mayores o con problemas motores que viven solos.

Existen infinidad de dispositivos para la detección de caídas en el mercado existente. Desde sistemas de propósito específico como las alarmas de detección de caídas en el baño basadas en una correa atada a la muñeca, a sistemas multipropósito basados en un dispositivo de captura y otro de procesamiento por separado, pasando por complejos métodos de captura y procesamiento de imágenes. Todos estos sistemas adolecen o bien de restricciones geográficas (funcionan o bien en una habitación o entorno geográfico limitado por el alcance de las cámaras o cobertura del enlace radio con la base de procesamiento) o bien resultan poco prácticos e incluso obtrusivos en una sociedad no acostumbrada a

vivir en un mundo dominado por la tecnología.

1.1.2. planteamiento del trabajo

cómo se puede resolver el problema qué se propone descripción de objetivos en términos generales

La evolución de la potencia de los microprocesadores y miniaturización de los sensores ha permitido generalizar y extender el uso de dispositivos "llevables.^{a)} al grueso de la población. Estos avances se aprovechan ya parcialmente en algunas soluciones a este problema, donde se utilizan los datos capturados por el acelerómetro de una pulsera de actividad o reloj inteligente ya sea para realizar una detección simplista de una caída (una aceleración fuerte y abrupta) con altas tasas de fallos o bien para enviar este flujo de datos a un segundo sistema, normalmente un móvil, para realizar la detección. Ambas soluciones tienen sus pros y contras. La primera tiene a su favor la alta disponibilidad al aunar captura y tratamiento en la misma unidad, pero falla al usar algoritmos poco eficaces, al contrario que la segunda opción que se aprovecha de la mayor potencia de un segundo centro de cómputo para mejorar la detección a costa de una mayor complejidad en el sistema que reduzca su usabilidad y disponibilidad. Hay que tener en cuenta que el público objetivo de esta tecnología es un segmento de población con escasos conocimientos de nuevas tecnologías.

La solución propuesta es aprovechar la mejora en rendimiento de los procesadores de sistemas portables como los usados en relojes inteligentes para, al igual que en la primera solución, realizar tanto captura como tratamiento y detección de caídas en la misma unidad. La diferencia es que el algoritmo usado se base en los últimos avances en tecnologías de predicción temporal con inteligencia artificial, redes recurrentes LSTM bidireccionales con mecanismos de atención y detección de anomalías para implementar un sistema de detección autónomo en quasi-tiempo real que a la vez sea lo menos obtrusivo para el usuario final, como podría ser el simple hecho de llevar un reloj puesto.

El objetivo es por tanto implementar una solución de detección de caídas con alta precisión, siendo esta al menos comparable a la conseguida en sistemas con cómputo externo, que funcione exclusivamente en un reloj inteligente.

1.1.3. Estructura de la memoria

qué hay en cada uno de los subsiguientes capítulos

(Desarrollar) Un capítulo de estado del arte, otro de objetivos (qué aportamos sobre el estado del arte).

Un capítulo sobre la descripción del problema, el dataset y su estructura (requisitos). Explicar peculiaridades sobre las señales del acelerómetro usadas tanto a nivel físico (frecuencia, valores) como fisiológico. En este sentido explicar qué se considerará un episodio, su longitud y magnitudes elegidas justificar dichas decisiones así como exponer todo tratamiento de datos realizado al dataset. Explicar como se consigue la estacionariedad de la señal o qué efecto tiene la estacionariedad en la decisión del tamaño del episodio.

Otro sobre la aplicación y el algoritmo de detección final usado y como presenta los resultados (IHM).

Finalmente la presentación de resultados, evaluación con respecto a las soluciones existentes (simple detección por "threshold", sistemas basados en RNN para el smartpone e incluso un modelo arima o similar no basado en redes neuronales. Incluir precisión y si es posible latencia. Explicar mecanismos de test y como se ha conseguido el conjunto de datos de test. Si da tiempo a probarlo lo suficiente como para tener un conjunto de datos estadísticamente significativo, añadir los resultados.

Resumen de la conclusión.

Capítulo 2

Contexto y Estado del Arte

En líneas generales

2.1. Precedentes en detección de caídas

2.1.1. Primeros pasos, cálculos basados en cotas

Sobre cálculos basados en cotas, tenemos el FallIndex [1], Kangas[2] lo compara con el uso ya sea de aceleración vertical o modulo de la aceleración y de nuevo obtiene resultados dispares según el tipo de caída simulada. Este índice probablemente lo usemos como algoritmo de comparación dado que no requiere información de postura/posición del acelerómetro.

En [3] se compara el rendimiento de los métodos basados en cotas sobre la aceleración registrada por un acelerómetro usando un teléfono como fuente de medida y análisis. Se desprenden los resultados: Los metodos con buenos resultados en pruebas de laboratorio/controladas no dan buenos resultados en experimentos de uso real y viceversa (se achaca al valor de las cotas, calibradas con demasiada especificidad para el experimento en laboratorio) Los métodos con buena sensibilidad tienen especificidad muy mala y al revés. Si queremos 100 % de sensibilidad la especificidad puede descender hasta el 11 % (Bourke 1LFT) y para un 98 % de especificidad una sensibilidad del 14 % (Kangas1D) Incluso el mejor de los algoritmos, Chen, da unos valores de especificidad 24 % y sensibilidad 94 %. Claramente insuficientes para la detección de caidas. Los moviles se llevan en la mano o en la cintura.

Al ser estos métodos computacionalmente eficientes, son utilizados en sistemas em-

bebidos donde tanto potencia de cálculo como la potencia son altamente restringidos. El acercamiento de usar relojes o pulseras para la captura de movimiento se presenta ya por [4] usando tanto el smartphone como una pulsera para la captura, aunque el procesamiento se realiza en el smartphone. Comprara los resultados con iFall y Fade con resultados muy dispares según el tipo de caída aunque usa algoritmos básicos basados en modulo de la aceleración o FallIndex (crean un dataset llamado project gravity solo con gente joven)

Luque[5] analiza multitud de sistemas de detección de caídas que usan un teléfono inteligente android para al menos una de las etapas (captura de datos, procesado y detección o proxy hacia un servidor externo) que hagan uso o no de terceros dispositivos. Los algoritmos estudiados son: 1- Monitorizado básico (usar módulo del vector aceleración y un threshold X) 2- Fall Index (Yoshida, T.; Mizuno, F.; Hayasaka, T.; Tsubota, K.; Wada, S.; Yamaguchi, T. A Wearable Computer System for a Detection and Prevention of Elderly Users from Falling. In Proceedings of the 12th International Conference on Biomedical and Medical Engineering (ICBME), Singapore, Singapore, 7–10 December 2005.) 3- PerFallD (Dai, J.; Bai, X.; Yang, Z.; Shen, Z.; Xuan, D. PerFallD: A Pervasive Fall Detection System using Mobile Phones. In Proceedings of the 8th IEEE International Conference on Pervasive Computing and Communications Workshops (PERCOM Workshops), Mannheim, Germany, 29 March–2 April 2010; pp. 292–297) (usa también un giroscopio) 4- iFall (Sposaro, F.; Tyson, G. IFall: An Android Application for Fall Monitoring and Response. In Proceedings of the Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC 2009), Minneapolis, MN, USA, 2–6 September 2009; pp. 6119–6122.)

Realmente el monitorizado básico no está tan lejos del resto de métodos e incluso son mejores que algunas implementaciones propietarias comerciales. Recalca: alta variabilidad de los resultados según el tipo de caída (están demasiado optimizados para un tipo concreto, no son de uso general), también hace hincapié en los problemas de usabilidad por parte de usuarios no expertos.

2.1.2. IA para detección de caídas

Usando inteligencia artificial, Shi [6] describe un método basado en acelerómetro triaxial llevado en la cintura para predecir caídas, tratando una caída como una actividad humana más y usando métodos similares a los usados para la predicción de actividad

humana (CNN). Casilari (paper ejemplar en estructura) [7] usa una red de 4 capas convolucionales para lo mismo, y compara el rendimiento sobre multitud de datasets obteniendo que si bien se puede optimizar el rendimiento para un conjunto en concreto logrando resultados de precisión y especificidad del orden del 100 %, no es posible generar un modelo que generalice a todos los datasets [estudia también las precisiones variando el tamaño de la ventana y el threshold de potencia del modulo de la aceleración y llega a la conclusión de que ventanas de 1 segundo son las que mejor se comportan, casa con la definición de episodio de los resultados obtenidos del análisis del dataset casero. Hassan [8] mejora los resultados, sin embargo ambos usan gran potencia de cálculo y no es aplicable al uso de sistemas embebidos. Madrano [9] usa K-NearestNeighbours y SVM para detectar actividad y varios tipos de caídas, mostrando buenos resultados con SVM que además parece ser capaz de distinguir caídas para las que no ha sido entrenado.

Finalmente, en [10] tenemos un resumen con los últimos avances y resultados. Introduce otras fuentes de información como es el riesgo biológico, o predisposición a la caída debido a la edad y otros factores de deterioro de la salud. Muy interesante. CUIDADO!

Un estudio similar al de Luque realiza Aziz[11, 12] Llega a conclusiones similares respecto a la alta variabilidad de los resultados, especialmente en los métodos basados en cotas. Sin embargo encuentra que SVM llega a generalizar incluso con tipos de caídas para las que no había sido entrenado. En la segunda obra analiza en más detalle la detección con SVM usando caídas reales y sugiere usar una combinación de métodos basados en cotas junto con técnicas de IA para obtener mejores estimadores.

2.2. GRU vs LSTM para predicción de series

Respecto al uso de LSTM para detectar anomalías en series temporales, Wang [13] usa LSTM para identificar anomalías en la señal de un motor (aunque el usa el error de reconstrucción de la descomposición y recomposición wavelet de la señal como entrada a una triple red LSTM, nuestro enfoque es el contrario: usar LSTM a modo de transformada wavelet y luego comparar el error de recomposición).

Li[14] usa redes con varias capas LSTM bidireccionales para la predicción de actividad humana y caídas usando acelerómetro y radar, capturando en la muñeca mientras consigue resultados comparables a las mejores técnicas de clasificación.

Qin[15] estudia el comportamiento de varias redes recurrentes para la predicción

de la saturación de oxígeno en el agua y obtiene que las GRU son las que mejores predicciones (menos error) obtienen (Sobre LSTM e incluso RNN bidireccional). Kofi [16] comparas LSTM y GRU para predecir mercado de valores con topologías muy variadas (número de celdas, de capas, stateless o no) y encuentra que GRU tiene mejor tasa de aciertos teniendo en cuenta el coste computacional (y muchas veces sin tenerlo) y que no siempre tener dos capas de RNN da mejores resultados.

2.3. Pruning y técnicas para reducir complejidad de modelos

TODO

Capítulo 3

Objetivos

Puente entre el estudio y la contribución. Debe contener:

1. objetivo general
2. objetivo específico
3. metodología de trabajo

Los objetivos deben ser *SMART*

- Specificl (objetivo claro)
- Measurable (se pueda medir el éxito o fracaso)
- Attainable (viable su conecución con el tiempo y recursos disponibles)
- Relevant (que tenga un impacto demostrable)
- Time-related (que se pueda realizar en un tiempo determinado)

3.1. Objetivo General

Un poco la descripción a grandes rasgos de qué se espera (como si se lo explicases a tuabuela) Ejemplo: Mejorar el servicio de audio grúa de un museo con una guía interactiva por voz valorada positivamente con un 4/5 al menos.

Implementar un sistema de detección de caídas que se ejecute en un smartwatch con una tasa de detección comparable a los sistemas basados en "thresholds" del acelerómetro y mucho menor ratio de falsos positivos.

3.2. Objetivos Específicos

- Desarrollar un conjunto de datos para el experimento
- Estudiar el comportamiento y características de las señales temporales del acelerómetro.
- Identificar y establecer una magnitud derivada de la lectura del acelerómetro que permita su posterior trabajo
- Desarrollar un sistema predictor basado en los puntos anteriores
- cuantificar el grado de satisfacción con el sistema obtenido y comparar con los sistemas existentes

Conjunto de objetivos más específicos alcanzables por separado. suelen ser los diferentes pasos a seguir para conseguir el objetivo general. Han de ser smart, los verbos deberían ser: • Analizar Calcular Clasificar Comparar Conocer Cuantificar Desarrollar Describir Descubrir Determinar Establecer Explorar Identificar Indagar Medir Sintetizar Verificar

3.3. Metodología de trabajo

Debe describir los pasos que se van a dar, el por qué de cada paso, instrumentos a utilizar y cómo se van a analizar los resultados.

1. Generar un nuevo dataset ¹

- a) Los existentes se basan en detección de actividades
- b) Los pocos basados en detección de caídas se restringen a un subconjunto de caídas muy específico y muchas veces con posiciones del elemento de detección diferente de la usada en el estudio

2- Estudiar el dataset obtenido a- comprender mejor el comportamiento de las señales capturadas b- buscar parámetros importantes para llevar a cabo la detección

2. Implementar un sistema basado en LSTM y detección de anomalías usando errores de predicción. Mecanismo atencional basado en potencia de señal de entrada?

¹ Se implementa una app para ello, y se realiza un procesamiento de los datos obtenidos

- Implementar una red LSTM FORWARD, y/o una FORWARD-BACKWARD, Asi como un sistema basado en threshold (usar GRU con RELU para mejorar la eficiencia de cómputo)
- Una vez entrenados los modelos con información de actividad ordinaria:
 - Implementar una app que o bien en tiempo real o cuando detecte un cierto nivel de actividad lance los modelos de predicción
 - Usar un sistema que comparando la señal real y la predicha decida si es una .anomalía.º no, lo más básico un RMS del error de predicción.

3. Comparar los resultados con el estado del arte

- Entrenar el sistema usando al menos un dataset que incluya caídas.
- Comparar con al menos métodos de cota fall index y modulo aceleración.
- Comparar con estudios previos que usen el mismo dataset.
- Analizar los resultados con el dataset propio.

4. Prueba en uso real. (Si da tiempo)

- Entrenar el sistema con dataset creado.
- Usar en interno
- Probar en caídas simuladas
- Si es posible conseguir ejemplos de caídas reales (app debe enviar todos los eventos registrados como caídas e indicar si han sido confirmados, rechazados o ignorados)

Capítulo 4

Identificación de requisitos

Indicar el trabajo previo realizado para guiar el desarrollo del software. Debe identificar adecuadamente el problema a tratar, contexto adecuado de uso y funcionamiento de la aplicación. Idealmente se debería realizar con expertos en la materia a tratar.

???

Capítulo 5

Descripción de la herramienta desarrollada

Aportar detalles del proceso de desarrollo incluyendo fases e hitos del proceso, diagramas representativos de la arquitectura y funcionamiento, capturas de pantalla para ilustrar el funcionamiento, etc.

WIP

Capítulo 6

Evaluación

al menos una mínima evaluación de usabilidad de la herramienta y su aplicabilidad para resolver el problema resuelto.

Capítulo 7

Conclusiones y Trabajo Futuro

7.1. Conclusiones

7.2. Lineas de trabajo futuro

Lineas de trabajo que podrían aportar valor al TFM realizado. Perspectivas de futuro que abre el trabajo realizado. Justificar en qué modo puede emplearse la aportación desarrollada y en qué campos.

Bibliografía

- [1] T. Yoshida, F. Mizuno, T. Hayasaka, Ken-ichi Tsubota, Shigeo Wada, and T. Yamaguchi. A wearable computer system for a detection and prevention of elderly users from falling. *Proc ICBM*, 12:179–182, 01 2005.
- [2] Maarit Kangas, Antti Konttila, Per Lindgren, Ilkka Winblad, and Timo Jämsä. Comparison of low-complexity fall detection algorithms for body attached accelerometers. *Gait & posture*, 28:285–91, 09 2008.
- [3] Fabio Bagalà, Clemens Becker, Angelo Cappello, Lorenzo Chiari, Kamiar Amnian, Jeffrey M. Hausdorff, Wiebren Zijlstra, and Jochen Klenk. Evaluation of accelerometer-based fall detection algorithms on real-world falls. *PLOS ONE*, 7(5):1–9, 05 2012.
- [4] Thomas Vilarinho, Babak Farshchian, Daniel Bajer, Ole Dahl, Iver Egge, Sondre Hegdal, Andreas Lønes, Johan Slettevold, and Sam Weggersen. A combined smartphone and smartwatch fall detection system. 10 2015.
- [5] Luque R, Casilari E, Morón M-J, and Redondo G. Comparison and characterization of android-based fall detection systems. *Sensors*, 2014.
- [6] Jingyi Shi, Diansheng Chen, and Min Wang. Pre-impact fall detection with cnn-based class activation mapping method. *Sensors*, 20(17):4750, 2020. Copyright - © 2020. This work is licensed under <http://creativecommons.org/licenses/by/3.0/> (the “License”). Notwithstanding the ProQuest Terms and Conditions, you may use this content in accordance with the terms of the License; Last updated - 2020-10-01.
- [7] Eduardo Casilari, Raúl Lora-Rivera, and Francisco García-Lagos. A study on the application of convolutional neural networks to fall detection evaluated with multiple public datasets. *Sensors*, 20(5):1466, Mar 2020.

- [8] M. M. Hassan, A. Gumaei, G. Aloï, G. Fortino, and M. Zhou. A smartphone-enabled fall detection framework for elderly people in connected home healthcare. *IEEE Network*, 33(6):58–63, 2019.
- [9] Carlos Medrano, Raul Igual, Inmaculada Plaza, and Manuel Castro. Detecting falls as novelties in acceleration patterns acquired with smartphones. *PLOS ONE*, 9(4):1–9, 04 2014.
- [10] Anita Ramachandran and Anupama Karuppiiah. A survey on recent advances in wearable fall detection systems. *BioMed Research International*, 2020:17, 2020. Copyright - Copyright © 2020 Anita Ramachandran and Anupama Karuppiiah. This is an open access article distributed under the Creative Commons Attribution License (the “License”), which permits unrestricted use, distribution, and reproduction in any medium, provided the original work is properly cited. Notwithstanding the ProQuest Terms and Conditions, you may use this content in accordance with the terms of the License. <http://creativecommons.org/licenses/by/4.0/>; Last updated - 2020-04-30.
- [11] Omar Aziz, Magnus Musngi, Edward J. Park, Greg Mori, and Stephen N. Robnovitch. A comparison of accuracy of fall detection algorithms (threshold-based vs. machine learning) using waist-mounted tri-axial accelerometer signals from a comprehensive set of falls and non-fall trials. *Medical & Biological Engineering & Computing*, 55(1):45–55, 2017.
- [12] Omar Aziz, Jochen Klenk, Lars Schwickert, Lorenzo Chiari, Clemens Becker, Edward J. Park, Greg Mori, and Stephen N. Robnovitch. Validation of accuracy of svm-based fall detection system using real-world fall and non-fall datasets. *PLoS One*, 12(7), 07 2017. Name - Simon Fraser University; Copyright - © 2017 Aziz et al. This is an open access article distributed under the terms of the Creative Commons Attribution License: <http://creativecommons.org/licenses/by/4.0/> (the “License”), which permits unrestricted use, distribution, and reproduction in any medium, provided the original author and source are credited. Notwithstanding the ProQuest Terms and Conditions, you may use this content in accordance with the terms of the License; Last updated - 2020-08-03; SubjectsTermNotLitGenreText - Canada; British Columbia Canada.

- [13] Ruirui Wang, Zhan Feng, Sisi Huang, Xia Fang, and Jie Wang. Research on voltage waveform fault detection of miniature vibration motor based on improved wp-lstm. *Micromachines*, 11(8):753, 2020. Copyright - © 2020. This work is licensed under <http://creativecommons.org/licenses/by/3.0/> (the “License”). Notwithstanding the ProQuest Terms and Conditions, you may use this content in accordance with the terms of the License; Last updated - 2020-10-01.
- [14] Haobo Li, Aman Shrestha, Hadi Heidari, Julien le kernec, and Francesco Fioranelli. Bi-lstm network for multimodal continuous human activity recognition and fall detection. *IEEE Sensors Journal*, PP:1–1, 10 2019.
- [15] Hongqian Qin. Comparison of deep learning models on time series forecasting : a case study of dissolved oxygen prediction, 2019.
- [16] Koffi M. Koudjonou and Minakhi Rout. A stateless deep learning framework to predict net asset value. *Neural computing & applications*, 32(14):1–19, 2020.
- [17] Davide Anguita, Alessandro Ghio, Luca Oneto, Xavier Parra, and Jorge L. Reyes-Ortiz. A public domain dataset for human activity recognition using smartphones. In *21th European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning, ESANN 2013*, Bruges, Belgium, 4 2013.
- [18] Jorge-Luis Reyes-Ortiz, Luca Oneto, Alessandro Ghio, Albert Samá, Davide Anguita, and Xavier Parra. Human activity recognition on smartphones with awareness of basic activities and postural transitions. In Stefan Wermter, Cornelius Weber, Włodzisław Duch, Timo Honkela, Petia Koprinkova-Hristova, Sven Magg, Günther Palm, and Alessandro E. P. Villa, editors, *Artificial Neural Networks and Machine Learning – ICANN 2014*, pages 177–184, Cham, 2014. Springer International Publishing.
- [19] Angela Sucerquia, Jose Lopez, and J. Vargas-Bonilla. Sisfall: A fall and movement dataset. *Sensors*, 17:198, 01 2017.
- [20] George Vavoulas, Matthew Pediaditis, Charikleia Chatzaki, Emmanouil Spanakis, and Manolis Tsiknakis. The mobifall dataset: Fall detection and classification with a smartphone. *International Journal of Monitoring and Surveillance Technologies Research*, 2:44–56, 07 2016.

- [21] George Vavoulas, Charikleia Chatzaki, Thodoris Malliotakis, Matthew Pediaditis, and Manolis Tsiknakis. The mobiact dataset: Recognition of activities of daily living using smartphones. pages 143–151, 01 2016.
- [22] Leyuan Liu, Yibin Hou, Jian He, Jonathan Lungu, and Ruihai Dong. An energy-efficient fall detection method based on fd-dnn for elderly people. *Sensors*, 20(15):4192, 2020. Copyright - © 2020. This work is licensed under <http://creativecommons.org/licenses/by/3.0/> (the “License”). Notwithstanding the ProQuest Terms and Conditions, you may use this content in accordance with the terms of the License; Last updated - 2020-08-26.

Apéndice A

Captura de datos y construcción del dataset

A.1. Captura de datos y creación del dataset

A.1.1. Necesidad

Dos son las principales causas que motivan la tarea de generar un conjunto de datos propios para la realización de este trabajo: su carácter de prototipo experimental y la carestía de conjuntos de datos aplicables al problema y materiales disponibles públicamente. Como mencionaremos, ambas causas suponen un fuerte peso en la decisión final.

Los conjuntos de datos que podemos encontrar disponibles públicamente que puedan asociarse directamente con el proyecto con una calidad y documentación adecuada son escasos. En la mayoría de los casos los datasets disponibles son demasiado específicos al experimento para el que fueron creados o al sistema material utilizado o con información irrelevante para este trabajo. Ejemplos usados son los datasets para el reconocimiento de actividades [17, 18], (estadísticas en <https://github.com/srvds/Human-Activity-Recognition>). Casilari [7] lista todos los datasets disponibles así como detalles de los mismos (actividades, sensores, captura y posición...). Si no los principales parecen ser SisFall [19] (dos acelerómetros y giroscopio, caídas simuladas), MobiFall [20], MobiAct [21] (incluye caídas, puede ser buen ejemplo para benchmark), tFall[9], DLR y ProjectGravity [4]

En segunda instancia, al ser el objetivo último una implementación funcional de un

prototipo, las exigencias sobre el tipo y formato de los datos quedan supeditadas a las disponibles en la plataforma de desarrollo y test. Aunque factores como la frecuencia de muestreo, resolución o valores máximos de los datos pueden ser adaptadas de los conjuntos de datos pre-existentes, prescindiremos en gran medida de estos para evitar el coste de realizar dicho tratamiento así como reducir las posibles fuentes de errores en el experimento entrenando el prototipo final con el dataset generado.

Este conjunto de datos será también usado durante la etapa de validación de los resultados con respecto al estado del arte, aunque no pueda ser utilizado para una comparación directa, si debería servir para obtener una aproximación del rendimiento.

A.1.2. Captura de datos: AccelCapture

Con el fin de obtener un conjunto de datos para el entrenamiento, test y validación del sistema, se opta por implementar una primera aplicación para la plataforma de desarrollo.

Datos Capturados

Frecuencia de muestreo del acelerómetro Rango de valores Error/Resolución del acelerómetro Nombre del Portador del dispositivo Si disponibles (y no es nunca) actividad realizada tal y como es automáticamente detectada por el dispositivo

A.1.3. Dispositivo de captura

Especificaciones

A.1.4. Preprocesado de los datos

En un primer instante, durante el proceso de captura de datos se analiza un subconjunto con unas 200 muestras capturadas para observar las propiedades de los datos. Mediante un estudio de la periodicidad usando autoconvolución de las secuencias para buscar la posible periodicidad de los eventos. Como puede observarse en los resultados, obtenemos que las secuencias tienen poca correlación consigo mismas y por tanto a medio y largo plazo ninguna dependencia temporal. Así pues y como conviene a nuestro experimento decidimos trabajar con subsecuencias que llamaremos eventos. Estos eventos tendrán una relación de XXX muestras y como puede comprobarse al repetir los

Nombre	Fossil Gen3 Sport
Tamaño Pantalla	1,4"
Formato de Pantalla	Circular
Tipo de Pantalla	Táctil color (AMOLED)
Resolución Pantalla	454 x 454 px
Bluetooth	4.1
Wifi	802.11 b/g/n
ROM	4GBytes
RAM	512MBytes
CPU	Snapdragon 2100
OS	WearOS 2
Sensor Freq. Cardiaca	Si
Giroscopio	Si
Aclerómetro	3 ejes

Tabla A.1: Especificaciones del dispositivo de referencia

análisis de autocorrelación, si guardan una mayor dependencia temporal consigo mismo y con los eventos vecinos de la misma secuencia temporal. El objetivo de estos eventos es poder contener una acción completa (ya sea el gesto de mirar la hora, una zancada o una caída). Esta noción de evento será reciclada en el transcurso de la implementación de solución final convirtiéndose en el episodio a predecir de la red LSTM.

Filtrado de ruido

Los estudios siguientes demuestran que el filtrado de ruido mejora la capacidad de tratamiento posterior Tian, T.; Sun, S.; Lin, H. Distributed fusion filter for multi-sensor systems with finite-step correlated noises. Inf. Fusion 2019, 46, 128-140.

Luego, para el caso de natación Xiao, D.; Yu, Z.; Yi, F.; Wang, L.; Tan, C.C.; Guo, B. Smartswim: An infrastructure-free swimmer localization system based on smartphone sensors. In Proceedings of the International Conference on Smart Homes and Health Telematics, Wuhan, China, 25-27 May 2016; pp. 222-234.

decide que una promediado por ventana flotante de tamaño M es el que mejores resultados da: $G_{filter} = \frac{1}{M} \sum_{i=0}^M G_i$. (Explicado en Liu [22] que usa este método con una

DeepNN basada en capas CNN + 2xLSTM + Fully Connected + Softmax).

Apéndice B

Artículo